GSLC Deep Learning Session 5: Bagian A

Nama : Zahra' Zakiyyah Priyono
NIM : 2802492554

1. Efek Regularisasi pada Batch Normalization

   Pada saat training, Batch Normalization normalisasi aktivasi dengan rata-rata dan varians mini-batch. Keduanya hanya estimasi yang berisik dari statistik populasi dan berubah setiap iterasi karena komposisi batch diacak. Output sebuah sampel jadi bergantung pada sampel lain dalam batch. Noise ini mirip Dropout dan membesar saat batch kecil (Ioffe & Szegedy, 2015). Saat inferensi dipakai running statistics yang deterministik

   Asumsi "menghilangkan Dropout" tidak berlaku pada tiga kondisi:

   a. Batch sangat kecil sehingga statistik akan noisy dan training tidak stabil.
   b. Dropout dipasang sebelum Batch Normalization yang menghasilkan variance shift antara training dan test (Li et al., 2019).
   c. Model berkapasitas besar dengan data sangat sedikit memberikan efek Batch Normalization yang "mild" tidak cukup mencegah overfitting.

   Referensi

   Ioffe, S., Szegedy, C.. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. *Proceedings of the 32nd International Conference on Machine Learning*, in *Proceedings of Machine Learning Research* 37:448-456 Available from https://proceedings.mlr.press/v37/ioffe15.html.

   Li, X., Chen, S., Hu, X., & Yang, J. (2019). Understanding the Disharmony Between Dropout and Batch Normalization by Variance Shift. *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2682-2690.

   Learning Material Session 05, Advanced CNNs and Transfer Learning. BINUS University. Slide 6-8.

2. Degradasi Jaringan Dalam dan Formulasi Residual

   Degradation problem adalah masalah optimasi, bukan overfitting: training error plain CNN yang lebih dalam ikut naik (He et al., 2016). Secara teoritis, lapisan tambahan bisa belajar identity mapping, tetapi solver sulit mengaproksimasikan $H(x) = x$ dengan tumpukan lapisan nonlinier.

   Blok residual memakai $y = F(x) + x$, sehingga model cukup belajar $F(x) = 0$ untuk meniru identitas. Saat backpropagation:

$$\partial L/\partial x = \partial L/\partial y \cdot (1 + \partial F/\partial x)$$

   Suku "1" menjadi jalur gradien langsung tanpa melewati bobot dan aktivasi.

   Pada jaringan sangat dalam, perkalian Jacobian berantai dapat menyusut eksponensial (vanishing gradient), dan shortcut menjaga gradien tetap sampai ke lapisan awal. Namun He et al. menilai degradasi pada plain net kemungkinan bukan vanishing gradient, karena jaringan dilatih dengan BN yang menjaga sinyal dan gradien tetap sehat. Mereka menduga konvergensinya sangat lambat.

References

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778.

Learning Material Session 05, Advanced CNNs and Transfer Learning. BINUS University. Slide 10-12.

3. Feature Extraction vs. Fine Tuning

Dimensi	Feature Extraction	Fine-Tuning
Trainable parameters	5.130 (hanya fc, 10 kelas)	layer4 + fc: 8.398.858 dari 11.181.642 (75%); seluruh jaringan: 100%
Kebutuhan data	Sedikit; parameter kecil, risiko overfitting rendah	Lebih banyak; parameter besar rentan overfit pada data kecil
komputasi/memori per epoch	Forward melalui backbone tetap berjalan; hemat ada di backward dan state optimizer	Gradien dan state optimizer untuk lapisan yang dibuka
Risiko merusak fitur	Nol untuk bobot, asalkan BN backbone di .eval(); tanpa itu running_mean tetap berubah	Ada bila LR terlalu besar (destructive gradient updates)

Kesimpulannya, pilih feature extraction bila data sangat sedikit, domain mirip ImageNet, atau komputasi terbatas. Pilih fine-tuning bertahap dengan LR kecil bila data cukup dan domain berbeda, karena fitur tingkat tinggi perlu disesuaikan (Yosinski et al., 2014).

References

Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? *ArXiv, abs/1411.1792*.

Learning Material Session 05, Advanced CNNs and Transfer Learning. BINUS University. Slide 14-16.

4. Kaidah Penerapan Data Augmentation

Augmentasi acak hanya untuk train set karena tujuannya memperluas variasi training data sebagai regularisasi. Validation/test set harus mengukur performa pada distribusi tetap, sehingga metrik stabil dan dapat direproduksi. Preprocessing deterministik (Resize, CenterCrop, Normalize) tetap dipakai di val/test; yang dinonaktifkan hanya augmentasi acak. Bila augmentasi dibuat sebelum split, versi turunan image yang sama bisa masuk ke train dan test (data leakage), sehingga metrik terlalu optimistik.

Contoh tidak layak: hue jitter ekstrem. Warna bulu langsung menentukan label (mis. Bengal vs Egyptian Mau), jadi transformasi ini bisa mengubah label (tidak label-preserving). Sebagai pelengkap, vertical flip tidak mengubah label, tetapi keluar dari distribusi data nyata sehingga membuang kapasitas.

References

Learning Material Session 05, Advanced CNNs and Transfer Learning. BINUS University. Slide 20, 21, and 23.

5. Mitigasi Catastrophic Forgetting

Bobot pretrained berada di basin loss yang baik untuk ImageNet. Saat adaptasi, gradien dari head yang masih acak dan data sedikit bisa besar. Dengan learning rate tinggi, bobot terlempar dari basin itu dan fitur umum tertimpa (Kirkpatrick et al., 2017).

Strategi mitigasi:

a. Differential learning rate / discriminative fine tuning
   LR kecil untuk lapisan awal (1e-4 untuk layer4), lebih besar untuk fc (1e-3). Lapisan awal menyimpan fitur generik yang perlu dijaga (Howard & Ruder, 2018).
b. Gradual unfreezing
   Buka lapisan dari yang teratas ke bawah secara bertahap. Head beradaptasi dulu, sehingga gradien yang sampai ke backbone lebih bermakna.
c. Linear warmup
   Menaikkan LR perlahan agar langkah awal tidak merusak bobot (Goyal et al., 2017).

References

J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A.A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska, D. Hassabis, C. Clopath, D. Kumaran, & R. Hadsell, Overcoming catastrophic forgetting in neural networks, Proc. Natl. Acad. Sci. U.S.A. 114 (13) 3521-3526, https://doi.org/10.1073/pnas.1611835114 (2017).

Howard, Jeremy and Ruder, Sebastian (2018). Universal language model fine-tuning for text classification. ACL 2018 - 56th Annual Meeting of the Association for Computational Linguistics, Melbourne, Australia, 15-20 July 2018. Stroudsburg, PA, United States: Association for Computational Linguistics .https://doi.org/10.18653/v1/p18-1031.

Goyal, P., Dollár, P., Girshick, R.B., Noordhuis, P., Wesolowski, L., Kyrola, A., Tulloch, A., Jia, Y., & He, K. (2017). Accurate, Large Minibatch SGD: Training ImageNet in 1 Hour. *ArXiv, abs/1706.02677*.

Learning Material Session 05, Advanced CNNs and Transfer Learning. BINUS University. Slide 28-29.