Laporan Analisis

C0. Tujuan dan Setup

1. Tujuan

   Membandingkan *training from scratch*, *feature extraction*, dan *fine-tuning* ResNet-18 pada klasifikasi 10 ras (5 kucing, 5 anjing) Oxford-IIIT Pet dengan data terbatas, serta menguji peran augmentasi dari arsitektur yang lebih efisien.

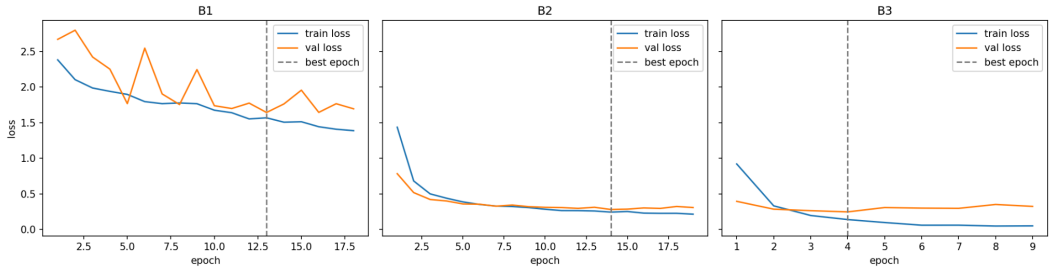
2. Setup
   a. Data: 10 kelas, 1.973 gambar, *split* stratified 70/15/15 menjadi 1.381/296/296, dengan *assert* tidak ada *overlap* antar-*split*.
   b. Protokol: ResNet-18 (bobot IMAGENET1K_V1), batch 32, AdamW (*weight decay* 1e-2), CrossEntropyLoss. *Early stopping* memantau val loss (maks. 40 epoch, *patience* 5, bobot terbaik dipulihkan) dan khusus untuk B1_ext memakai maks.60 epoch dan *patience* 10. Evaluasi memakai Resize(256), CenterCrop(224), dan normalisasi ImageNet. Seed 42 untuk Python, NumPy, dan PyTorch.
   c. Environment: torch 2.11.0+cu130, torchvision 0.26.0+cu130, GPU Tesla T4.

3. Keputusan Desain
   a. Backbone beku di-.eval(). requires_grad=False tidak menghentikan pembaruan *running statistics* BatchNorm. Notebook membuktikan running_mean berubah tanpa .eval() dan tetap dengan .eval(). Di B3, BN layer4 tetap mode *train* karena ikut dilatih.
   b. Augmentasi aktif di B1-B3 sebagai kontrol. Efeknya diuji terpisah di B4, hanya pada B3.
   c. Mode *failure analysis* dipilih berdasarkan val accuracy, bukan test.

C1. Tabel Konsolidasi dan Kurva Pembelajaran

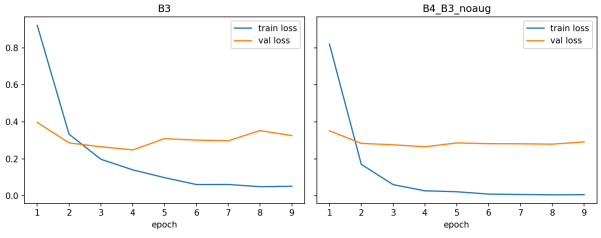
A	B	C	D	E	F	G	H	I	J	K	L	M	N
Kondisi	Strategi	Trainable	Total	LR	Best ep	Epoch run	Waktu (s)	s/epoch	Train acc	Val acc	Test F1	Gap	Latensi ms/b32
B1	Scratch (patience 5)	11181642	11181642	0.001	13	18	266.5	14.8	0.452	0.399	0.411	0.053	
B1_ext	Scratch (patience 10, run tambahan)	11181642	11181642	0.001	39	49	718.9	14.7	0.689	0.514	0.504	0.176	
B2	Feature extraction	5130	11181642	0.001	14	19	261.1	13.7	0.941	0.885	0.892	0.055	
B3	Fine-tune layer4 + aug	8398858	11181642	0.0001/0.001	4	9	125.4	13.9	0.979	0.902	0.895	0.077	31.7
B4	B3 tanpa augmentasi	8398858	11181642	0.0001/0.001	4	9	90.7	10.1	1	0.909	0.898	0.091	
B5a	EfficientNet-B0	1142202	4020358	0.0001/0.001	10	15	204.7	13.6	0.986	0.926	0.905	0.06	40.6
B5b	MobileNetV3-S	951642	1528106	0.0001/0.001	4	9	119.5	13.3	0.948	0.882	0.894	0.066	8.3

Gambar 1. Results_summary: Gap = train acc (tanpa augmentasi) - val acc. Seed 42.



Gambar 2. curves_B1_B2_B3

Kurva train loss versus val loss B1, B2, B3. garis putus-putus menandai epoch terbaik. B1 turun lambat dengan val loss berayun, sedangkan B2 konvergen mulus dengan kurva train dan val hampir berhimpit. B3 mencapai val loss minimum pada epoch 4, setelah itu val loss mendatar sementara train loss terus menurun.



Gambar 3. curves_B4: Kurva B3 dengan versus tanpa augmentasi.

A	B	C	D	E	F
cond	seed	val_acc	test_f1	gap	best_epoch
B2	42	0.8851351142	0.8917386818	0.05548763275	14
B2	43	0.8918918967	0.8981065999	0.03931736946	20
B2	44	0.8817567825	0.8869610348	0.04148721695	16
B3	42	0.9020270109	0.8949262528	0.07697373629	4
B3	43	0.895270288	0.8958532808	0.06997227669	3
B3	44	0.895270288	0.9048559392	0.07938575745	5
B4_noaug	42	0.9087837934	0.8979951944	0.09121620655	4
B4_noaug	43	0.9155405164	0.8952799454	0.08445948362	7
B4_noaug	44	0.9189189076	0.911896603	0.08108109236	5

Gambar 4. Results_multiseed: Tiga seed (42, 43, 44), rata-rata ± std.

Model	Total param.	Trainable	Test F1	Waktu (s)	Latensi (ms/batch 32)
ResNet-18 (B3)	11.181.642	8.398.858	0,895	125,4	31,7
EfficientNet-B0	4.020.358	1.142.202	0,905	204,7	40,6
MobileNetV3-S	1.528.106	951.642	0,894	119,5	8,3

Tabel 1. Efisiensi B5: Latensi diukur batch 32 pada input acak.

C2. Pembahasan Analisis Komparatif

1. Disparitas B1 vs B2/B3

   B1 melatih 11.181.642 parameter dari 1.381 gambar latih dan hanya mencapai val acc 0,399 serta macro F1 0,411 (train acc 0,452, jadi *underfitting*; val loss berayun hingga 2,80 pada epoch 2). B2 dan B3 mencapai F1 0,892 dan 0,895. Arsitekttur oprimizer, dan augmentasi sama; yang berbeda hanya inisialisasi, bagian yang dilatih, dan *learning rate* (B3: 1e-4 untuk layer4 dan 1e-3 untuk fc; B1 dan B2: 1e-3). Selisih ini bukan soal ResNet sulit dilatih (Slide 10-12), melainkan data yang terlalu sedikit untuk mempelajari fitur dari nol dibanding fitur Imagenet yang sudah tersedia (Slide 15-16). B1_ext (49 epoch, 718,9 s) naik sekitar 9 poin F1 menjadi 0,504 tetapi tetap sekitar 39 poin di bawah B2/B3, jadi kesimpulan tidak bergantung pada protokol *early stopping*. Oxford-IIIT Pet berdekatan dengan domain ImageNet (Slide 15), sehingga selisih ini kemungkinan lebih besar daripada di domain yang jauh.
2. B2 vs B3

   Test F1 setara: 0,8923 ± 0,0056 vs 0,8985 ± 0,0055 (3 seed), dan uji McNemar seed 42 memberi p = 1,0 (13 vs 14 prediksi *discordant*). Selisih val acc (0,8863 vs 0,8975) sekitar 1,1 pp, di bawah SE sekitar 1,7 pp untuk n = 296, dan val dipakai memilih epoch, sehingga dibaca setara. Perbedaannya ada pada dinamika. Pada seed 42, B3 selesai dalam 125,4 s (9 epoch) dan B2 dalam 261,1 s (19 epoch); rata-rata 3 seed, *best epoch* B3 adalah 4,0 ± 1,0 dan B2 16,7 ± 3,1. B3 melatih 8,4 juta parameter (75%) pada data kecil, sehingga gap lebih besar (0,075 vs 0,045) dan val loss seed 42 naik dari 0,248 ke 0,353 setelah epoch 4. Ini *overfitting* pada banyak parameter yang dapat dilatih, sesuai trade-off *feature extraction* vs *fine-tuning* (Slide 16). Pada seed 42, confidence B3 lebih tinggi baik saat benar (0,924 vs 0,882) maupun saat salah (0,739 vs 0,676; 31 vs 32 kesalahan), jadi ini pergeseran umum, bukan *overconfidence* khusus pada kesalahan. *Catastrophic forgetting* (Slide 28) tidak diukur, sehingga tidak ada klaim.
3. Peran augmentasi (B4, pada B3)

   Tanpa augmentasi, val acc 0,9144 vs 0,8975 (selisih 1,7 pp), tetapi test F1 hanya 0,9017 vs 0,8985 (selisih 0,3 pp, dalam std). Gap 0,086 vs 0,075; penurunan gap ini lebih tepat dibaca sebagai training yang lebih sulit (train acc seed 42: 1,000 menjadi 0,979), bukan generalisasi yang membaik. Val loss tanpa augmentasi tetap 0,265-0,291 pada epoch 4-9 seed 42 walau train acc 1,000, artinya menghafal belum merusak val. Ini konsisten dengan dugaan *early stopping* menghentikan training sebelum efek regularisasi muncul. Data ini tidak mendukung klaim Slide 20 bahwa augmentasi memperbaiki generalisasi pada data kecil, setidaknya pada protokol ini.

C3. Failure Analysis

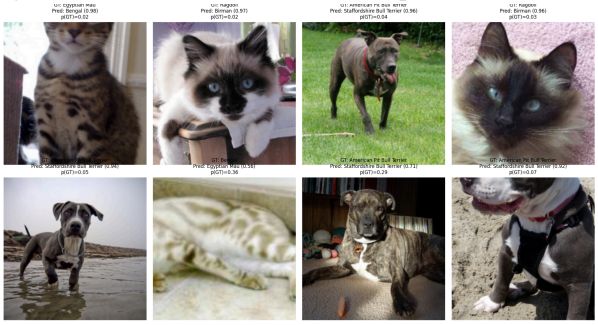
Untuk setup dalam *failure analysis*, model yang dianalisis adalah EfficientNet-B0 (B5a), dipilih dari val acc tertinggi di antara 5 kandidat (0,9257). Model ini salah pada 28 dari 296 gambar test. Sampel yang

ditampilkan: 5 kesalahan dengan confidence tertinggi ditambah 3 kesalahan acak (seed 42), sehingga sampel tidak mewakili seluruh kesalahan.

Jumlah	Label Asli	Prediksi
8	American Pit Bull Terrier	Staffordshire Bull Terrier
6	Ragdoll	Birman
3	Staffordshire Bull Terrier	American Pit Bull Terrier
3	Egyptian Mau	Bengal
3	Bengal	Egyptian Mau
2	Abyssinian	Bengal

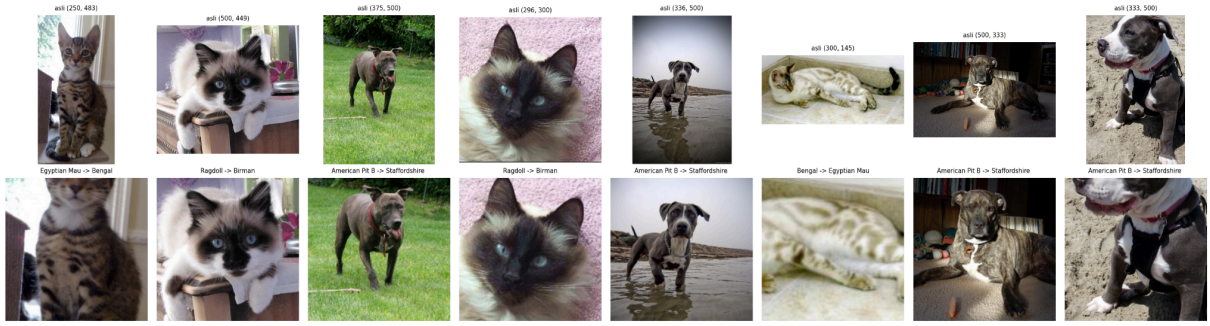
Tabel 2. Pasangan konfolusi

Asimetri APBT menjadi STaffordshire (8) vs arah sebaliknya (3) tidak dapat dibedakan dari kebetulan (uji binomial eksak dua sisi, n = 11, p ≈ 0,23).



Gambar 5. Figure_analysis

Delapan kesalahan test set, dengan label asli, prediksi, confidence, dan p(GT).



Gambar 6. Crop_check

Baris atas: gambar asli; baris bawah: hasil Resize (256) dan CenterCrop(224). Berdasarkan inspeksi visual, bagian subjek terpotong pada 3 dari 8 sampel (Egyptian_Mau_84, Bengal_135, APBT_46).

Hipotesis per sampel yaitu keyakinan menandai kekuatan dukungan, bukan hasil uji.

Sampel	Asli	Prediksi (conf; p(GT))	Pengamatan	Hipotesis
Egyptian_Mau_84	Mau	Bengal (0,89; 0,02)	250x483; crop menyisakan sekitar 45% tinggi; mata dan telinga hilang	Wajah hilang. Ketegangan: seharusnya confidence rendah, tetapi 0,98. Alternatif: bintik dada terbaca sebagai pola Bengal, ambiguitas pola, atau label noise (rendah).
Ragdoll_136	Ragdoll	Birman (0,97; 0,02)	500×449; tidak terpotong berarti	Kemiripan ras (colorpoint, bulu semi-panjang, mata biru); bukan crop (sedang, verifikasi ke standar ras)
APBT_15	APBT	Staffordshire	375×500; tubuh utuh di rumput	Kemiripan ras bully; ukuran dan

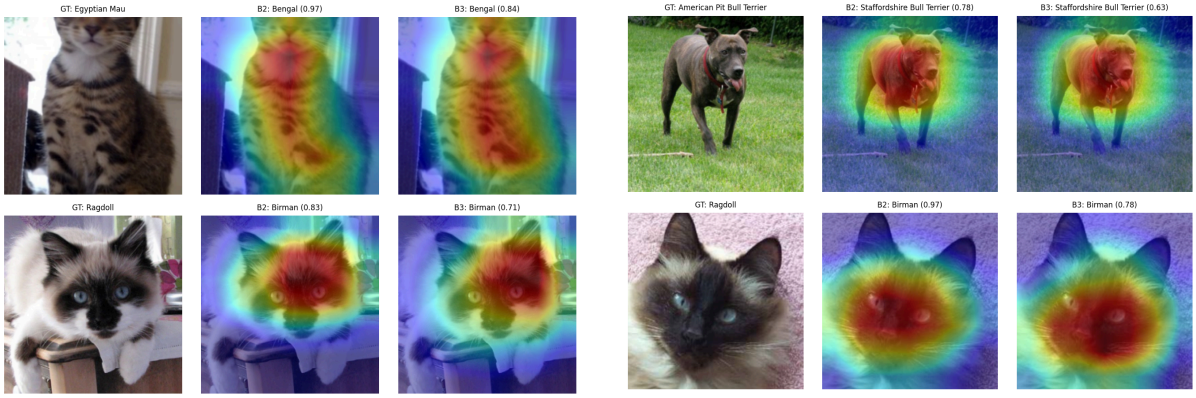
		(0,96; 0,04)		proporsi kepala sulit dinilai dari foto (rendah, verifikasi).
Ragdoll_245	Ragdoll	Birman (0,96; 0,03)	296×300; close-up wajah tanpa petunjuk tubuh	Seperti Ragdoll_136, ditambah petunjuk tubuh tidak ada (sedang)
APBT_88	APBT	Staffordshire (0,94; 0,05)	336×500; air dangkal, sudut rendah	Latar air dan sudut rendah tidak lazim (rendah)
Bengal_135	Bengal	Mau (0,56; 0,36)	300×145; crop sekitar 42% lebar setelah diperbesar sekitar 1,77× (145 -> 256); kepala dan ekor hilang	Informasi hilang dan blur; konsisten dengan confidence rendah (rendah-sedang)
APBT_1	APBT	Staffordshire (0,71; 0,29)	500×333; brindle di karpet, kontras cahaya, rak buku	Pencahayaan dan latar memicu keraguan antar-ras (rendah)
APBT_46	APBT	Staffordshire (0,92; 0,07)	333×500; close-up dada dengan harness; crop sekitar 58% tinggi memotong mata dan atas kepala	Wajah terpotong, tetapi kesalahannya confident (rendah)

Confidence keempat sampel APBT tidak dapat dipakai untuk menyimpulkan pola, karena dua di antaranya (APBT_15, APBT_88) masuk sebagai lima kesalahan ber-confidence tertinggi dan dua lainnya (APBT_1, APBT_46) dipilih secara acak. Pola confidence baru dapat dinilai dari seluruh kesalahan APBT menjadi Staffordshire.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

1. Rekomendasi
    a. Data terbatas (~140 gambar/kelas, domain dekat ImageNet): mulai dari feature extraction (B2); hanya 5.130 parameter, kurva stabil, F1 setara B3 (0,8923 vs 0,8985).
    b. Butuh konvergensi cepat: pilih *fine-tuning* layer4 (B4); ~4 vs ~17 epoch, tapi gap lebih besar (0,074 vs 0,045) dan early stopping wajib.
    c. Augmentasi (B4): tidak menambah akurasi pada protokol ini; perlu diuji pada variasi pengambilan gambar yang lebih besar.
    d. Latensi terbatas: MobileNetV3-Small (F1 0,894; 8,3 ms/batch) menyamai B3 dengan latensi ~3,8× lebih rendah; EfficientNet-B0 F1 tertinggi (0,905) tapi paling lambat (40,6 ms). Selisih B5-B3 (~1 poin, satu seed) tidak bermakna.
    e. Berlaku untuk domain dekat ImageNet, ~1,4 ribu gambar, 10 kelas, resolusi tetap, GPU kelas Colab.
2. Limitasi
    a. Cakupan data: satu dataset dengan 10 kelas yang dekat dengan domain ImageNet.
    b. Jumlah seed: hanya B2, B3, dan B4 yang diulang 3 seed, sedangkan B1; B1_ext, dan B5 satu seed.
    c. Ukuran sampel: test set 296 gambar (SE akurasi sekitar 1,7 pp), jadi selisih kecil tidak bermakna.
    d. Val set dipakai untuk *early stopping* dan pemilihan model *failure analysis*, sehingga val acc sedikit optimistis.
    e. Preprocessing B5: eval_tf dibuat dari bobot ResNet-18 dan dipakai juga untuk EfficientNet dan MobileNetV3, sehingga ada kemungkinan ketidaksesuaian interpolasi (perlu verifikasi di dokumentasi torchvision).
    f. Strategi fine-tuning: B3 membuka layer4 sekaligus, tanpa *gradual unfreezing* atau lr_scheduler (Slide 16, 29).
    g. Waktu per epoch hampir sama antar kondisi (sekitar 13,3-14,8 s), kecuali B4 tanpa augmentasi (10,1s). B3 dan B4 memakai model yang identik, jadi selisih 13,9 vs 10,1 s adalah bukti tidak langsung bahwa augmentasi di CPU memperlambat training.
    h. Latensi diukur pada input acak, tanpa *data loading*.
    i. Hipotesis crop hanya didasarkan pada inspeksi visual (Resize(256) + CenterCrop(224) memotong sebagian subjek pada 3 dari 8 sampel).

C5. Eksplorasi Tambahan



Gambar 7. gradcam_B2_vs_B3: Grad-CAM pada layer 4 untuk B2 (backbone beku) dan B3 (layer4 di-fine-tune), 4 sampel kesalahan.

Sesuai slide 29, representasi divisualkan sebelum dan sesudah *fine-tuning*; pada keempat sampel B2 dan B3 menyorot area yang sangat mirip dan memprediksi kelas yang sama, meskipun confidence B3 lebih rendah (0,84, 0,71, 0,63, 0,78 vs 0,97, 0,83, 0,78, 0,97). Temuan ini tidak dapat digeneralisasi dan tidak bertentangan dengan C2.2 karena keempat sampel termasuk lima kesalahan EfficientNet-B0 dengan confidence tertinggi (sampel sulit), sedangkan pada seluruh test set seed 42 confidence rata-rata B3 justru lebih tinggi daripada B2 (0,924 vs 0,882 saat benar; 0,739 vs 0,676 saat salah). Keterbatasannya: hanya 4 sampel, semuanya kesalahan, dan B2 vs B3 bukan pembanding murni sebelum-sesudah karena classifier head keduanya dilatih terpisah.

Referensi

Parkhi, O.M., Vedaldi, A., Zisserman, A., & Jawahar, C.V. (2012). Cats and dogs. *2012 IEEE Conference on Computer Vision and Pattern Recognition*, 3498-3505.

Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun; Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770-778

Tan, M. & Le, Q.. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *Proceedings of the 36th International Conference on Machine Learning*, in *Proceedings of Machine Learning Research* 97:6105-6114 Available from https://proceedings.mlr.press/v97/tan19a.html.

Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, Bo Chen, Mingxing Tan, Weijun Wang, Yukun Zhu, Ruoming Pang, Vijay Vasudevan, Quoc V. Le, Hartwig Adam; Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2019, pp. 1314-1324

Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, Dhruv Batra; Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017, pp. 618-626

Learning Material Session 05, Advanced CNNs and Transfer Learning. BINUS University.

Lampiran: Pernyataan Penggunaan AI (AI Disclosure Statement)

1. Alat AI yang digunakan: Claude (Anthropic), via claude.ai
2. Ruang lingkup bantuan: Memandu langkah pengerjaan (laporan dan susunan kode) serta review draf Bagian A dan C: memeriksa kesesuaian angka dan log, dan menunjukkan kekeliruan klaim dan sitasi.
3. Cara verifikasi: Seluruh kode saya jalankan sendiri, angka laporan disalin dari results.json / results_summary.csv, perbaikan hasil review saya cocokkan dengan output notebook, sitasi saya cek ke masing-masing halaman sumber, rujukan slide saya cocokkan langsung dengan slide kuliah.